

Implementasi Fine-Tuning OpenAI Whisper Base untuk Automatic Speech Recognition Bahasa Minangkabau

Fathan Andi Kartagama
NIM 122140055




Program Studi Teknik Informatika
Institut Teknologi Sumatera

Sidang Akhir Skripsi April 2026

Rencana Presentasi / *Outline*

- 1 Latar Belakang
- 2 Metodologi & Dataset
- 3 Strategi & Inovasi
- 4 Hasil & Evaluasi
- 5 Kesimpulan & Saran

- Teknologi *Automatic Speech Recognition* (ASR) saat ini masih bias pada bahasa bermodal besar (*high-resource*).
- **Bahasa Minangkabau:**
 - Cenderung berada di level *extremely low-resource* (1,3 jam data latih terbuka).
 - Minim standarisasi tulisan ortografis untuk format audio ke teks.
- Model generik seperti Whisper *zero-shot* menunjukkan error sangat tinggi ketika menghadapi variasi dialek lokal.



Komparasi error *zero-shot* vs run terbaik Freeze Encoder dan LoRA.

Tujuan Penelitian

- 1 **Adaptasi Bahasa Baru:** Melakukan *fine-tuning* model pralatih (*pre-trained*) OpenAI Whisper Base ke bahasa Minangkabau.
- 2 **Komparasi Strategi Efisiensi:** Membandingkan dua strategi efisien: *Freeze Encoder* dan *Low-Rank Adaptation* (LoRA).
- 3 **Evaluasi Metrik:** Menilai kinerja konversi dari audio menggunakan *Word Error Rate* (WER) dan *Character Error Rate* (CER).


Deskripsi Data:

- **Sumber:** LibriVox Indonesia (Terjemahan Deklarasi HAM / UDHR ke Bahasa Minangkabau).
- **Kuantitas:** 156 file audio dengan total durasi $\sim 1,3$ jam.
- **Text Preprocessing:**
 - Case folding (huruf kecil).
 - Pembersihan tanda baca khusus (*punctuation removal*).
 - Pembuangan karakter non-alfabet.

Skema Validasi & Eksperimen:

- Menggunakan **5-Fold Cross-Validation**.
- Bertujuan mengoptimalkan set data yang sangat terbatas dan memastikan tidak ada bias dari *random seed* tertentu.
- Pada setiap iterasi 5 fold: 4 fold untuk *training*, 1 fold untuk *evaluation*.
- Augmentasi hanya diterapkan pada data *training* untuk menjaga integritas evaluasi.

Arsitektur Dasar: OpenAI Whisper



Gambar: Arsitektur OpenAI Whisper

Whisper Base Model

- **Total Parameter:** 74 juta.
- Arsitektur **Encoder-Decoder Transformer**.
- Memproyeksikan fitur audio (*Log-Mel Spectrogram*) menjadi barisan token bahasa melalui atensi (*cross-attention*).
- Sudah *pre-trained* multibahasa, namun tetap perlu adaptasi untuk bahasa *extremely low-resource* seperti Minangkabau.



Gambar: Flow penelitian pada skripsi

Skema Eksekusi Eksperimen

- 5-fold *cross-validation* pada 156 audio.
- Setiap fold: 4 fold *train*, 1 fold *eval*.
- Augmentasi **hanya** pada data *train*.
- *Early stopping* berbasis WER evaluasi.

Audio & Teks Preprocessing

- Konversi MP3 → WAV, *resampling* ke 16 kHz.
- Normalisasi amplitudo dan *silence trimming*.
- *Lowercase*, normalisasi tanda baca, pembersihan teks.

Data Augmentation (train-only)

- *Speed Perturbation*: faktor 0.85–1.15.
- *Noise Injection*: SNR 10–30 dB.
- *Pitch Shift*: ± 2 semitone.
- *SpecAugment*: *time/frequency masking*.

Strategi Adaptasi Fine-Tuning

Strategi 1: Freeze Encoder

- Membekukan seluruh **encoder**, hanya melatih **decoder**.
- Parameter terlatih ~ 37 juta ($\sim 50\%$ dari model Whisper Base).
- Mempertahankan kemampuan ekstraksi fitur akustik dasar Whisper, memaksa dekoder fokus murni memetakan pola ke teks bahasa Minang tanpa merusak representasi akustik yang general.

Strategi 2: LoRA (PEFT)

- **Low-Rank Adaptation:** Menginjeksi matriks ber-rank kecil ($r = 16$, $\alpha = 32$) ke dimensi linear model utama (q , k , v , out_proj , $fc1$, $fc2$).
- Sangat efisien: Hanya melatih $\sim 2,16$ Juta parameter ($\sim 2,93\%$ dari seluruh bobot model).
- Dapat ditambahkan sebagai *adapter weights* sangat kecil di atas model utama.

Inovasi Pendekatan (WCE & Temporal Separation)

Weighted Cross-Entropy (WCE)

- Distribusi token (huruf/kata) sangat *imbalance* di dataset lokal.
- WCE memberikan bobot penalti token secara adaptif berdasarkan tingkat kesulitan prediksi riwayat sebelumnya.
- Memaksa model memberi perhatian penalti lebih pada token (kata) yang sering keliru.

Temporal Separation (Validasi Non-Leakage)

- Digunakan bersamaan dengan WCE dalam pipeline 5-Fold.
- Bobot WCE **hanya** dihitung secara kumulatif dari *training history* folder/run sebelumnya.
- *Zero Data Leakage*: Mencegah metrik distribusi dari data evaluasi saat ini "bocor" saat melatih fold tersebut.

Konfigurasi Hyperparameter Terbaik (Fase 3)

Hyperparameter	Freeze Encoder (run_20260303_202534)	LoRA (lora_20260305_205845)
Parameter dilatih	~ 37 juta (50%)	~ 2,16 juta (2,93%)
Max Steps (per 1 Fold)	400 langkah	400 langkah
Strategi Loss	WCE + Temporal Separation	WCE + Temporal Separation
Learning Rate	2×10^{-5}	5×10^{-4}
LR Scheduler	Cosine	Cosine
Effective Batch Size	16	16
Weight Decay	0,01	0,05
Dropout Rate	0,1	0,1
Label Smoothing Factor	None	0,1
LoRA Dropout	-	0,15
Beam Width (Greedy)	5	5

Konfigurasi Augmentasi (Khusus Training Set)

Speed Perturbation (0.85–1.15x), *Noise Injection* (SNR 10-30 dB), *Pitch Shift* (± 2 semitone), dan *SpecAugment* (Time-masking=10/50, Freq-masking=10/40).

Hasil Evaluasi Akhir Keseluruhan

Skenario Model / Baseline	WER (%)	CER (%)
Zero-Shot Whisper Original	89,44	31,02
Freeze Encoder Terbaik (run_20260303_202534)	18,24 $\pm$ 2,18	3,87 $\pm$ 0,61
LoRA Terbaik (lora_20260305_205845)	15,67 $\pm$ 1,02	3,32 $\pm$ 0,38


- Kriteria pemilihan run terbaik: **mean WER paling kecil** pada 5-fold cross-validation (tie-breaker: mean CER).
- Perbaikan terhadap *zero-shot*: Freeze Encoder turun **79,61%** dan LoRA turun **82,48%** pada WER.
- LoRA memberi nilai rata-rata error terbaik sekaligus simpangan antar-fold yang lebih kecil dibanding Freeze Encoder.

Rincian Performa Tiap Fold (Run Terbaik FE vs LoRA)


Skenario Model	Freeze Encoder (run_20260303_202534)		LoRA (lora_20260305_205845)	
Partisi Lipatan	WER (%)	CER (%)	WER (%)	CER (%)
Fold Ke-1 (#0)	18,58	3,86	16,28	3,71
Fold Ke-2 (#1)	16,10	3,37	14,63	3,16
Fold Ke-3 (#2)	16,52	3,03	14,49	2,90
Fold Ke-4 (#3)	22,22	4,48	17,20	2,99
Fold Ke-5 (#4)	17,78	4,62	15,74	3,84
Rata-rata/Mean $\pm$ Std	18,24 $\pm$ 2,18	3,87 $\pm$ 0,61	15,67 $\pm$ 1,02	3,32 $\pm$ 0,38

- Freeze Encoder terbaik di WER terjadi pada Fold #1 (16,10%), sedangkan CER terbaik terjadi pada Fold #2 (3,03%).
- LoRA memiliki WER dan CER terbaik pada Fold #2 (14,49% dan 2,90%).
- Variasi hasil antar-fold pada LoRA lebih sempit sehingga performa lebih konsisten.

Komparasi Cross-Validation: FE Terbaik vs LoRA Terbaik



Gambar: Distribusi WER, CER & Waktu Evaluasi **FE** terbaik




Gambar: Distribusi WER, CER & Waktu Evaluasi **LoRA** terbaik

Dashboard Evaluasi Metrik Menyeluruh


Freeze Encoder (run_20260303_202534)

Whisper Fine-tuning Dashboard - Minangkabau Language



LoRA (lora_20260305_205845)


Whisper Fine-tuning Dashboard - Minangkabau Language



Dashboard menunjukkan LoRA lebih stabil antar-fold, terutama pada sebaran WER dan CER.


Progres Kurva Loss dan Konvergensi Pelatihan

Kurva Loss Freeze Encoder (FE terbaik)



Gambar: Fluktuasi Loss Train vs Eval FE terbaik

Kurva Loss LoRA (LoRA terbaik)




Gambar: Konvergensi Loss Train vs Eval LoRA terbaik

Kurva *loss* menunjukkan konvergensi LoRA yang lebih stabil pada 5-fold validasi dibandingkan Freeze Encoder.


Dinamika Pelatihan LoRA Terbaik: Learning Rate & Gradient Norm

Penjadwalan LR Cosine LoRA ($\alpha = 5 \times 10^{-4}$)



Gambar: Jadwal Learning Rate LoRA pada 5-fold

Norm Gradien Global Model LoRA



Gambar: Stabilitas norm gradien LoRA pada 5-fold

Kedua grafik berasal dari run LoRA terbaik (lora_20260305_205845) dan menunjukkan peluruhan LR yang halus serta norm gradien yang stabil selama pelatihan 5-fold.

Analisis Kesalahan Pasca-Training (Kualitatif)

Penjabaran kualitatif menunjukkan 3 permasalahan bahasa daerah:

1. Substitusi Fonetik karena Variasi Bunyi Analog

Penggantian bunyi konsonan antar pengguna bervariasi luas.

- Asli: *panghormatan* → Prediksi: *pangormatan* (huruf *h* tidak terdengar tebal).
- Asli: *dasar* → Prediksi: *tasar* (Konsonan lemah).

2. Segmentasi Kosakata (Tidak ada Pengejaan Baku)

Kata sering terpotong atau terhubung (*Word Boundaries Blur*).

- Asli: *mukadimah* → Prediksi: *muka di ma*.
- Asli: *hak-hak* → Prediksi: *hak hak* (tanpa sepasang tanda strip).

3. Halusinasi Model Autoregresif

Ketik dihadapkan dengan jeda diam *prolonged silence*, atensi model sering menyantumkan gibberish dekoder dari kata lampau.

Kesimpulan Umum & Kontribusi

Kesimpulan Adaptasi ASR Minangkabau

Kombinasi adaptasi pe-parameter efisien *Low-Rank Adaptation* (LoRA), penalti terbobot adaptif (*Weighted Cross-Entropy*), dan instrumen validasi silang bebas kebocoran (*Temporal Separation*) adalah solusi mutakhir untuk mengonversi data *extremely low-resource* (1,3 Jam) menjadi representasi ASR berkualitas tinggi.

Sintesis Hasil Eksekusi

- Lompatan akurasi masif: WER dari *baseline Zero-Shot* sebesar 89,44% direduksi secara stabil hingga rata-rata $15,67\% \pm 1,02\%$ pada LoRA terbaik (lora_20260305_205845).
- Efisiensi Pelatihan: LoRA mampu menyamai bahkan mengungguli kemampuan Freeze Encoder dengan komputasi bobot matriks linier ~ 17 kali lebih sedikit dilatih (hanya $\sim 2,16$ juta parameter dari 74 juta).
- Kestabilan Varians *Cross-Validation*: 5-Fold menunjukkan LoRA mengamankan standar deviasi yang sangat ketat ($\pm 1\%$ di WER) dibandingkan Freeze Encoder.

Saran Pengembangan Lanjutan

- Perluasan Kualitas & Kuantitas Dataset:** Kendala fonetik terbesar bukan pada arsitektur *attention* semata, melainkan tiadanya keragaman audio. Menginisiasi *crowdsourcing* (percakapan non-deklarasi / spontan) akan sangat mendongkrak utilitas ASR di skenario lapangan harian.
- Studi Komparatif Skala Model:** Melakukan komparasi performa dari adaptasi efisien pada tier *Whisper Small*, *Medium*, dan *Large* untuk menyelidiki titik setimbang antara skala parameter model lawan laju presisi *low-resource*.
- Standardisasi *Text Normalizer Khusus Daerah*:** Membuat pedoman penyambungan leksikal ortografi Minangkabau khusus ASR, guna menekan drastis *CER* dan *word boundary error* (contoh: disambiguasi *mukadimah* vs *muka di ma*).

TERIMA KASIH

Sesi Tanya Jawab | Mohon masukan dan bimbingan dari Dewan Penguji.